

Rapport

Påbøl

30. maj 2019

Kapitel 1

Uge 2: 30/04

1.1 Kvadratiske matricer

En $N \times N$ matrix D er en diagonalmatrix hvis $d_{ij} = 0$ for $i \neq j$

Enhedsmatricen I_n er denne $n \times n$ diagonalmatrix

$$\begin{bmatrix} 1 & 0 & \dots & 0 \\ 0 & 1 & \dots & \dots \\ 0 & \dots & 0 & 1 \end{bmatrix}$$

1.2 Inversible matricer

En $n \times n$ matrice er invertibel hvis der findes en $n \times n$ matrix så

$$XA = AX = I_n$$

Altså hvis både AX og XA giver identitetsmatricen

Hvis både X_1 og X_2 er inverse til A så gælder:

$$X_2 = X_2 I_n = X_2 (AX_1) = (X_2 A) X_1 = I_n X_1 = X_1$$

Derfor er den inverse matrice entydigt bestemt og betegnes A_{-1}

En invertibel matrix A kaldes også regulær, ellers kaldes den singulær

Hvis A er invertibel så har ligningen $Ax = y$ netop en løsning $x = A^{-1}y$

1.2.1 Theorem p. 85

Hvis A og B er invertible så er AB også invertibel og der gælder $(AB)^{-1} = B^{-1}A^{-1}$

Hvis A er invertibel så er A^T også invertibel og $(A^T)^{-1} = A$

Hvis A er invertibel så er A^{-1} også invertibel og $(A^{-1})^{-1} = A$

Hvis A er invertibel og $S \neq 0$ så er sA også invertibel og $s^{-1}A^{-1} = (sA)^{-1}$

1.2.2 Def 2.8

En $N \times N$ matrix X er højreinvert til A hvis $AX = I_n$

Hvis $XA = I_n$ er X venstreinvert

1.2.3 Theorem 2.4

Hvis der findes netop en matrix X som er en højreinvert til A så er X også venstreinvert til A og dermed $X = A^{-1}$

1.3 Bestemmelse af invers ved rækkeoperationer

Lad A være en $N \times N$ matrix og lad $I = I_n$

1. Opskriv matrixen $[A|I]$
2. Bring matrixen $[A|I]$ til reduceret rækkeechelonform
3. Hvis den reducerede rækkeechelonform er $[I|X]$ da er $A^{-1} = X$ hvis ikke da er A ikke invertibel

Kapitel 2

07/05

2.1 Vektorrummet \mathbb{R}^n

Der gælder pene rægneregler
Multiplikation er ikke heeeelt simpelt

En mængde V hvis elementer er vektorer med

- Vektoraddition, $V \times V \rightarrow V, (u, v) \rightarrow u + v$
- Skalarmultiplikation $\mathbb{R} \times V \rightarrow V, (s, u) \rightarrow su$

Mængden $V = \mathbb{R}^n$ er et reelt vektorrum

VI holder os fra abstrakte vektorrum Men alt hvad vi skal lære om \mathbb{R}^n gælder også i et abstrakt vektorrum V

2.2 Underrum

Pæne delmængder i \mathbb{R}^n

En delmængde $u \subseteq \mathbb{R}^N$ har tre krav

Nulvektoren skal ligge i u

For alle $u, v \in u$ gælder også $u + v \in u$

For alle $s \in \mathbb{R}$ og $u \in U$ gælder det $su \in U$

Eksempler er: $U = \{(0, 0)\}$, $U =$ en linie gennem $0, U = \mathbb{R}$

Hvad kan man bruge underrum til? Principal component analysis. Der tilnærmer man et højdimensionalt datasæt med et lavdimensionalt underrum.

Eksempel 2.1. Vi går til \mathbb{R}^4 .

$u = \{(x_1, x_2, x_3, x_4)\} \in \mathbb{R}^4 | x_1 + x_2 = 2 \text{ og } x_2 + x_3 + x_4 = 0$

Vi opstiller følgende operation

$$x = \begin{pmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{pmatrix} \Leftrightarrow \begin{pmatrix} 1 & 1 & 0 & 0 \\ 0 & 1 & 1 & 1 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \Leftrightarrow Ax = 0$$

Da $A0 = 0$ gælder $0 \subseteq U$

Hvis $u, v \in U$ gælder $Au = 0$ og $Av = 0$. Matrixregning giver

$$A(u + v) = Au + Av = 0 + 0 = 0$$

og dermed gælder $u + v \in U$

Lad $s \in \mathbb{R}$. Det gælder at $s(u + v) \in U$ og da

$$A(su) = sAu = s \cdot 0 = 0$$

2.3 Span

Lad $S = \{v_1, \dots, v_k\} \in \mathbb{R}$. Sæt

$\text{span} S = \text{span}\{v_1, \dots, v_k\} = \{x_1 v_1, \dots, x_k v_k \mid x_1, \dots, x_k \in \mathbb{R}\}$ dvs $\text{span} S$ er mængden af alle linearkombinationer af v .

I planen \mathbb{R}^2 er spannet hele planen

Eksempel 2.2. Vi betragter i \mathbb{R}^3 vektorerne

$$\begin{pmatrix} a \\ 2 \\ 3 \end{pmatrix}, v_2 = (3, 4, 5), v_3 = (7, 8, 9)$$

Vektoren u tilhører $\text{span}(v_1, v_2, v_3)$ hvis der findes koefficienter x_n så det giver u

$$\begin{pmatrix} 1 & 4 & 6 \\ 2 & 5 & 8 \\ 4 & 6 & 9 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix}$$

Gauss jordan giver så til sidst et ligningssystem med en fri variabel. Altså der er uendeligt mange løsninger. Altså $u \in \text{span} v_1, v_2, v_3$

Derfra ser vi følgende. u ligger i spannet hvis

- u tilhører spannet.
- ligningssystemet $Ax = u$ har mindst en løsning

Theorem 3.2

Span er et underrum

Def 3.4

Lad u være et underrum af \mathbb{R}^n og lad $S \subseteq U$ være en endelig delmængde. Man siger at S udspænder U hvis $\text{span} S = U$

2.4 Lineær uafhængighed

Vi har de tre vektorer fra tidligere. De udspænder en 2d plan i \mathbb{R}^3 . Men vektor $v_3 \in \text{span}v_1, v_2$. Altså er v_3 overflødig. Derfor er de lineært afhængige

Definition 3.5 Lineær uafhængighed

Et set $S = \{v_1 \dots v_k\}$ af vektorer i \mathbb{R}^n kaldes afhængige hvis den eneste løsning til ligningen $x_1v_1 + \dots + x_kv_k = 0$ er $x_1 = \dots = x_k = 0$. Ellers er de lineært afhængige.

Eksempel 2.3. *Det kan skrives som*

$$\begin{pmatrix} 1 & 4 & 6 \\ 2 & 5 & 8 \\ 4 & 6 & 9 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix}$$

som på rre har en fri variabel, altså har de uendelig mange løsninger så de er Lineært afhængige

Bemærk: Hvis $v_4 \in \mathbb{R}^3$ er en vilkårlig vektor da er v_1, v_2, v_3, v_4 også lineært afhængige, da vi bare kan bruge den gamle løsning og sætte $x_4 = 0$

Sætter du det op på totalmatriceform ved du at hvis $\text{rank}A < k$ er systemet afhængigt

En konsekvens af det er

Theorem 3.5 Lad $n \times n$ er invertibel hvis og kun hvis søjlerne er lineært uafhængige.

Derudover så:

Theorem 3.6 $v_1, \dots, v_k \in \mathbb{R}^3$ er lineært uafhængige da $k \leq n$ eller fem vektorer i \mathbb{R}^4 skal være uafhængige

Derudover siger vi i et afhængigt. Der findes mindst en vektor v_i i spannet v_1, v_k

2.5 Baser

Lad U være et underrum af \mathbb{R}^n . en endelig delmængde $B \subseteq U$ kaldes en basis for U hvis: B er lineært uafhængigt og $\text{span}B = U$

2.5.1 Standardbasen for \mathbb{R}^n har en basis

Hvis $U \neq 0$ så har U uendeligt mange forskellige baser

Antallet af vektorer i en basis for et underrum er entydigt bestemt

Kapitel 3

09/05

3.1 Koordinater

Man skal have n retninger.

Definition 3.7 og Theorem 3.8

Lad $B = \{b_1, \dots, b_k\}$ være en ordnet basis for et underrum $U \subseteq \mathbb{R}^n$. Til hvert $v \in U$ findes entydigt bestemte tal $x_1, \dots, x_k \in \mathbb{R}$ så

$$v = x_1 b_1 + \dots + x_k b_k$$

Vektoren med disse tal kaldes koordinaterne for v mht. basen B

$$[v]_b = \begin{pmatrix} x_1 \\ \vdots \\ x_k \end{pmatrix}$$

Altså kan vi for ethvert punkt udspændt af B kan vi opskrive det på koordinatform vha. B . Vi kan finde koordinaterne til en vektor u ved at sætte dem op på et ligningssystem. Da:

$$v = x_1 b_1 + \dots + x_k b_k$$

$$[B]u \rightarrow [I_n][v]_b$$

3.1.1 Basisskiftmatricen

Kan omregne fra et koordinatsystem til et andet. Lad der være to ordnede baser b, c . Fra et og samme underrum $u \subseteq \mathbb{R}^n$. Basisskiftmatricen fra c til b er med notation fra 7.32 defineret ved $P_{b \leftarrow c}$ omreg

Vigtigt: $[v]_b = P_{b \leftarrow c} [v]_c$

Eksempel 3.1. Vi betragter to ordnede baser C, B

Vi udregner så alle koordinater til koldonner i C og lægger dem i matricen.

Derved får vi Basisskiftmatricen $P_{B \leftarrow C}$

Så hvis vi har en vektor $[v]_c$ kan vi udtrykke at $P \cdot [v]_c = [v]_b$

Øvelse

Vi har to baser:

$$B = \begin{bmatrix} 1 & 1 \\ 2 & 3 \end{bmatrix} E = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$$

Og en udleveret basisiskiftmatrice

$$P_{B \leftarrow E} = \begin{bmatrix} 3 & -1 \\ -2 & 1 \end{bmatrix}$$

Vi vil nu udtrykke $v = \begin{bmatrix} 5 \\ 6 \end{bmatrix}$ som koordinater i b

Vi ganger nu vektoren med matricen

$$Pv = \begin{pmatrix} 9 \\ -4 \end{pmatrix}$$

Derfor har vi

$$9 \begin{bmatrix} 1 \\ 2 \end{bmatrix} + -4 \begin{bmatrix} 1 \\ 3 \end{bmatrix}$$

3.1.2 Den inverse til basisskift matrice

Vi betragter at $P_{B \leftarrow C}$ er invertibel, og dens inverse $P_{b \leftarrow C}^{-1} = P_{c \leftarrow b}$

Så for at finde basisskift fra $P_{x \leftarrow E}$ kan vi bare finde den inverse matrice x

Vi kigger fra nu af på matrixen

$$A = \begin{pmatrix} 1 & 0 & 1 & 1 & 0 \\ 2 & 1 & 1 & 0 & 5 \\ 3 & 1 & 2 & 3 & 1 \\ 1 & 1 & 0 & 0 & 3 \end{pmatrix}$$

3.2 Nulrum

Null space på eng.

Nulrum er hvor det gælder $null A = \{x \in \mathbb{R}^n | Ax = 0\}$

3.3 Søjlerummet

Column space. Lad A være en $m \times n$ matrix. Søjlerummet af A er $col A = span\{allesøjleri A\}$

Vi kigger på rre for A

$$B = \begin{pmatrix} 1 & 0 & 1 & 0 & 2 \\ 0 & 1 & -1 & 0 & 1 \\ 0 & 0 & 0 & 1 & -2 \\ 0 & 0 & 0 & 0 & 0 \end{pmatrix}$$

Der er dog to afhængige variable. Vi finder de søjler hvor der står pivoter, altså vi skal beholde søjle 3 og fem og får

$$A' = \begin{pmatrix} 1 & 0 & 1 \\ 2 & 1 & 0 \\ 3 & 1 & 3 \\ 1 & 1 & 0 \end{pmatrix}$$

Som er vores basis

Vi ser så at dimensionen af Søjlerummet er 3dimensionelt $\dim(\text{col}(A)) = \text{rank}(A)$

3.4 Rækkerum

Lad A være en $M \times N$ matrix, rækkerummet af A er $\text{row } A = \text{span}\{\text{alle } m \text{ rækkevektorer i } A\}$

Sætter vi på rækkeechelonform. Så kan vi sige at alle nonzero rækker er vores $\text{span}(\text{som vektorer})$

Vi får at dimensionen af $\text{row } A = \text{rank } A$

Vi får at basis er de rækker hvori der befinder sig pivoter

3.5 Lineære transformationer

Lineære transformationer

En funktion $T : \mathbb{R}^N \rightarrow \mathbb{R}^m$ som respekterer plus og Skalarmultiplikation

Matrixtransformationer $T_A : \mathbb{R}^n \rightarrow \mathbb{R}^m$ givet ved $T_A(x) = Ax$ for alle $x \in \mathbb{R}^n$

Enhver matrixtransformation er lineær

3.18 Omvendt: Enhver lineær transformation er en matrixtransformation

Eksempel 3.2. Lad θ være en vinkel og lad $R_\theta : \mathbb{R}^2 \rightarrow \mathbb{R}^2$ være den funktion der roterer et punkt i planen vinklen θ mod uret omkring origo. Det er geometrisk klart at R_θ er en lineær transformation. Det at rotere respekterer plus og Skalarmultiplikation. Derfor siger sætning 3.18 at vi har en skjult matrice tilsvarende den

Vi tager de to standardvektorer e_1, e_2 . Roterer vi de to med θ

$$A_\theta = (R_\theta(e_1) | R_\theta(e_2)) = \begin{pmatrix} \cos\theta & -\sin\theta \\ \sin\theta & \cos\theta \end{pmatrix}$$

Eksempel 3.3. Vi kigger på spejling

Vi ser at

$$S \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} x \\ -y \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 0 & -1 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix}$$

3.5.1 Sammensætning af lineære transformationer

Lad der være givet to lineære transformationer $T(x) = Ax$ og $S(y) = By$

Den sammensatte transformation $S \circ T = S(T(x)) = S(Ax) = B(Ax) = (BA)x$

Eksempel 3.4. *Vi betragter nu både spejling og rotation med vinklen 40° . Vi har så $(S \circ R)$ roterer en vektor 40° og spejler den*

Vi har så $(R \circ S)$ Spejler en vektor og roterer med 40°

3.6 Kerne

Lad kernen af T være den lineære transformation $x \in \mathbb{R}^n | T(x) = 0$

Kernen er injektiv hvis $\ker T = \{0\}$

Kernen er surjektiv hvis alle vektorer bliver ramt af T

Rotationsmatricen er både injektiv og surjektiv.

Injektiv: Det vil sige alle vektorer der roteres og ender i nul er $(0, 0)$. Logik though

Surjektiv: Alle vektorer kan roteres over i $(Rot_{-40}(Rot_{40}(x)) = x)$

Hvis en lineær transformation både er injektiv og surjektiv (Bijektiv) dette svarer til at matricen A er invertibel. Den inverse lineære transformation er da $A^{-1}x$ hvor A er transformationsmatricen

Kapitel 4

14/05

4.1 Prikprodukt

Prikproduktet for to vektorer u, v er $u_1 * v_1 + u_2 \bullet gv_2 + \dots + u_n \bullet gv_n = u \bullet gv$
Vi har $s(u \bullet gv) = su \cdot sv$

4.1.1 Norm

Normen af en vektor er $\|v\| = \sqrt{v \bullet v}$ Se pyth

Regneregler:

- $\|v\| \geq 0$ og $\|v\| = 0$ netop hvis $v = 0$
- $\|cv\| = |c|\|v\|$
- $|u \bullet v| \leq \|u\|\|v\|$ Cauchy Schwarz ulighed
- $\|u + v\| \leq \|u\| + \|v\|$ (Trekantsuligheden)

4.2 enhedsvektor

En vektor $u \in \mathbb{R}^n$ kaldes en enhedsvektor hvis $\|u\| = 1$
For en vilkårlig vektor $u \neq 0$ i \mathbb{R}^n er den normerede vektor:

$$u' = \frac{u}{\|u\|}$$

4.3 Euklidisk afstand

Den euklidiske afstand mellem to vektorer i \mathbb{R}^n defineres som:

$$d(u, v) = \|u - v\| = \sqrt{(u_1 - v_1)^2 + \dots + (u_n - v_n)^2}$$

4.4 Vinklen mellem to vektorer

For u, v i \mathbb{R}^2 eller i \mathbb{R}^3 kan man vha. cosinusrelationerne vise

$$\cos \Theta = \frac{u \bullet v}{||u|| ||v||}$$

4.5 Ortogonale vektorer og pythagoras

For vinklen Θ mellem to vektorer u og v har man:

$$\Theta = 90 \quad \cos \Theta = \frac{u \bullet v}{||u|| ||v||} = 0 \Leftrightarrow u \bullet v = 0$$

Definition 4.5, to vektorer u, v i \mathbb{R}^n kaldes orthogonale hvis $u \bullet v = 0$ Der skrives $u \perp v$.

Theorem x.xx: Gælder det $u \perp v \in \mathbb{R}^n$ så gælder det at $||u+v||^2 = ||u||^2 + ||v||^2$
Er to vektorer orthogonale, så gælder det at

$$||u+v||^2 = ||u||^2 + ||v||^2$$

Da pythagoras sætning kan bruges på trekanten udspændt over de to retvinklede vektorer

4.6 Ortogonal projektion

Definition 4.6

Lad $u \neq 0$ være en vektor i \mathbb{R}^n og lad $U = \text{span}u$ være underrummet udspændt af u

For enhver vektor v i \mathbb{R}^n defineres nu:

- Den ortogonale projektion af v på U er givet ved:

$$\text{proj}_U(v) = \frac{v \bullet u}{||u||^2} u$$

- Komponenten af v ortogonal på U er en vektor der går vinkelret fra U til v

$$\text{comp}_U(v) = v - \text{proj}_U(v) = v - \frac{v \bullet u}{||u||^2} u$$

- Spejlingen af v i U er givet ved:

$$\text{refl}_U(v) = 2\text{proj}_U(v) - v = 2 \frac{v \bullet u}{||u||^2} u - v$$

4.6.1 øvelse


$$U = \text{span}u = \text{span} \begin{pmatrix} 1 \\ 1 \end{pmatrix}$$

og $v = \begin{pmatrix} 1 \\ 3 \end{pmatrix}$ Vi har $u \bullet v = 4$ Vi har $\|u\| = \sqrt{2} \Leftrightarrow \|u\|^2 = 2$

$$proj_U(v) = \frac{4}{2}u = 2u = \begin{pmatrix} 2 \\ 2 \end{pmatrix}$$

Vi har

$$comp_U(v) = v - proj_U(v) = \begin{pmatrix} -1 \\ 1 \end{pmatrix}$$



4.7 Projektionsmatricen

Det er keometrisk klart at $proj_U, comp_U, refl_U : \mathbb{R}^n \rightarrow \mathbb{R}^n$ er lineære transformationer. Derfor findes $n \times n$ matricer er

- P - Projektionsmatricen for U
- C - Komponentmatricen for U
- R - Spejlingsmatricen for U

Projektionsmatricerne

$$P = \frac{uu^T}{u^T u}$$

For uu^T er en søjlevektor gange rækkevektor får vi en matrice. u^T er række gange søjle, og derfor en skalar. Derfor får vi matrice divideret med skalar

$$C = I - P$$

$$R = 2P - I$$

4.8 Ortonormale baser

Et set af vektorer u_k kaldes

- Parvist ortogonale hvis $u_i \bullet u_j = 0$ for alle $i \neq j$
- Parvist ortonormale hvis $u_i \bullet u_j = 0$ for alle $i \neq j$ og $\|u_i\| = 1$ for alle i

Ethvert sæt S af parvist ortogonale ikke-nul vektorer i \mathbb{R}^n er lineært uafhængige
En ortogonal/ortonormal basis for et underrum U af \mathbb{R}^n er en basis B for U hvori vektorerne er parvist ortogonale/ortonormale

Hvis vi har en ortogonal base B så kan vi udregne koordinater:

$$[v]_B = \begin{pmatrix} \frac{v \bullet u_1}{\|u_1\|^2} \\ \vdots \\ \frac{v \bullet u_k}{\|u_k\|^2} \end{pmatrix}$$

4.9 Ortogonale Matrice

Vi har en matrix A og søjlerne i A er parvist ortonormale hvis og kun hvis $A^T A = I_K$ altså hvis A^T er venstre-invers til A

En kvadratisk matrix Q kaldes ortogonal hvis søjlerne i Q er parvist ortonormale altså hvis $Q^T Q = I_n$. Det gælder for den ortogonale matrice Q gælder $Q^{-1} = Q^T$

Ortogonale matricer bevarer prikprodukt: $Qu \bullet Qv = u \bullet v$.

4.9.1 Ortogonale lineære transformationer

Hvis vi har en lineær transformation hvor transformationsmatricen er ortogonal så får vi

Længden af den vektor vi starter med, og den transformerede vektor så bevarer de længden.

Typisk: Rotationer og spejlinger

Kapitel 5

16/05

5.1 Ortogonal komplement

Definition:

To underrum u og v af \mathbb{R}^n kaldes ortogonale hvis enhver vektor i u er ortogonal på enhver vektor i V dvs $u \bullet v = 0 \forall u \in U, v \in V$

Thm 4.8:

Lad $U = \text{span}\{u_1, \dots, u_p\}$ og $V = \text{span}\{v_1, \dots, v_q\}$ For at checke om underrum er ortogonale er det nok at checke 'frembringersæt'. Altså hvis du har to baser $U = \{u_1, u_2\}, V = \{v_1, v_2, v_3\}$ skal vi bare checke

$$u_1 \bullet v_1 = u_2 \bullet v_1 = u_1 \bullet v_2 = u_2 \bullet v_2 = u_1 \bullet v_3 = u_2 \bullet v_3 = 0$$

Def 4.11

Lad U være et underrum af \mathbb{R}^n det ortogonale komplement U^\perp til U består af samtlige vektorer som er ortogonale på alle vektorer i U : Det gælder

- U^\perp er et underrum af \mathbb{R}^n
- $U^\perp \cap U = \{0\}$
- $(U^\perp)^\perp = U$

Ortogonal komplementet til en linie er et plan

Thm 4.10. For enhver matrix A Gælder

$$(\text{row} A)^\perp = \text{null} A$$

$$(\text{col} A)^\perp = \text{null} A^\perp$$

$$(\text{null} A)^\perp = \text{row} A$$

Vi har også $\dim U + \dim U^\perp = n$ hvor n er fra \mathbb{R}^n

5.2 Ortogonal projektion

Vi har lært en-dimensionel projektion (eg vektor til vektor)

Vi skal nu projekttere generelt

Den ortogonale projektion af v på U er

$$proj_U(v) = \frac{v \bullet u_1}{\|u_1\|^2} u_1 + \dots + \frac{v \bullet u_k}{\|u_k\|^2} u_k$$

$$comp_U(v) = v - proj_U(v)$$

5.3 Gram-Schmidt processen

Gram-schmidt kan lave et ortogonalbasis til en ortonormalbasis

Lad u_1, \dots, u_n være lineært uafhængige vektorer, og dermed en basis for under-rummet $U = span u_1 u_n$. Vi normaliserer så

$$q_1 = \frac{u_1}{\|u_1\|}$$

MANGLER

5.4 QR faktorisering

Det er en måde at skrive en matrix som et produkt af to pæne matrixer, vi definerer u som søjler i A

Man laver Gram-Schmidt, og holder styr på tallene r_{ij}

$$q_1 = \frac{u_1}{\|u_1\|} = \frac{u_1}{r_{11}}$$

$$q_2 = \frac{u_2 - (u_2 \bullet q_1)q_1}{\|u_2 - (u_2 \bullet q_1)q_1\|} = \frac{u_2 - r_{12}q_1}{r_{22}}$$

Så har vi r_{ij}

$$A = QR = (q_1 | q_2 | \dots | q_n) \begin{pmatrix} r_{11} & r_{12} & \dots & r_{1j} \\ 0 & r_{22} & \dots & r_{2j} \end{pmatrix}$$

5.5 Mindste kvadraters metode

For en $m \times n$ matrix A betragter vi et lineært ligningssystem $Ax = b$, hvori der er mange ligninger med få ubekendte. Hvis ligningssystemet er inkonsistent, så efterspørger vi i stedet den vektor x som gør størrelsen $\|b - Ax\|$ mindst muligt. Altså den x der kommer tættest på b

Thm 4.13 viser at vi skal vælge $x = \bar{x}$ hvor $A\bar{x} = proj_{col A}(b)$

For \bar{x} gælder altså at $b - A\bar{x}$ er ortogonal til søjlerummet. Derfor ved vi at $A^T(b - A\bar{x}) = 0$ Den søgte vektor \bar{x} tilfredsstiller altså følgende ligningssystem $A^T A \bar{x} = A^T b$ Vi får så næsten altid (praktisk altid)

$$\bar{x} = (A^T A)^{-1} A^T b$$

Altså den vektor \bar{x} der kommer tættest på at løse ligningssystemet

Et eksempel på brug kunne være en samling datapunkter med tilsvarende x,y koordinater, vi har nu mange datapunkter(ligninger $y = ax + b$) og to ubekendte a, b)

Kapitel 6

forlasning 11

6.1 Diagonalisering af matricer

Det drejer sig om ligningen

$$P^{-1}AP = \begin{bmatrix} \lambda_1 & 0 & 0 \\ 0 & \lambda_2 & 0 \\ 0 & 0 & \lambda_3 \end{bmatrix}$$

En $n \times n$ matrix kaldes diagonaliserbar hvis der findes en matrix P og en diagonal-matrix som opfylder $P^{-1}AP = D$. Matricen $A = \begin{pmatrix} 1 & 1 \\ -2 & 4 \end{pmatrix}$ er diagonaliserbar fordi $P = \begin{pmatrix} 1 & 1 \\ 1 & 2 \end{pmatrix}$ og $D = \begin{pmatrix} 2 & 0 \\ 0 & 3 \end{pmatrix}$

6.2 Lidt teori

Vi antager at A er diagonaliserbar $n \times n$ matrix, dvs $P^{-1}AP = D$. Vi kan rykke lidt rundt og forgange med P på begge sider $P^{-1}AP = D \Rightarrow AP = PD$ og vi bemærker $Av_1 | \dots | Av_n = AP = PD = (\lambda_1 v_1 | \dots | \lambda_n v_n)$ Vi konkluderer at

- λ er en egen værdi for A med tilhørende egenvektor v .
- $\{v_1, \dots, v_n\}$ er en basis for \mathbb{R}^n bestående af egenvektorer i A

Theorem 6.1. 6.4 Lad A være en $n \times n$ matrix med k indbyrdes forskellige komplekse egen værdier. Vælg for hver $1 \leq i \leq k$ en basis B_i for egenrummet $E_{\lambda_i} = \text{Null}(A - \lambda_i I)$ så er mængden $B = B_1 \cup \dots \cup B_k$ lineært uafhængig og der gælder: A er diagonaliserbar og antallet af vektorer i $B = n$

6.3 En metode

Lad A være en $n \times n$ matrix med indbyrdes forskellige komplekse egen værdier $\lambda_1, \dots, \lambda_k$ hvor $k \leq n$

- Vælg basis $B_1 = v_1, \dots, v_{g_{\lambda_1}}$ for $E_{\lambda_1} = \text{Null}(A - \lambda_1 \cdot I)$

- ...
- Vælg basis $B_k = v_1, \dots, v_{g_{\lambda_k}}$ for $E_{\lambda_k} = \text{Null}(A - \lambda_k \cdot I)$

Vi opstiller så de baser som søjler i en

6.4 Øvelse

Vi får en matrix A

$$A = \begin{pmatrix} 2 & 3 \\ 3 & 2 \end{pmatrix}$$

Og vil bestemme P og D . Vi bruger sage

```
sage: a = matrix(SR,2,2,[2,3,3,2])
sage: a.eigenvalues()
[5, -1]
sage: a - (5*identity_matrix(2))
[-3  3]
[ 3 -3]
sage: (a - (5*identity_matrix(2))).rref()
[ 1 -1]
[ 0  0]
sage: b1 = vector([1,1])
sage: (a + identity_matrix(2))
[3 3]
[3 3]
sage: (a + identity_matrix(2)).rref()
[1 1]
[0 0]
sage: b2 = vector([-1,1])
sage: P = matrix(SR,2,2,[b1,b2]).T
sage: P
[ 1 -1]
[ 1  1]
sage: P.inverse()*a*P
[ 5  0]
[ 0 -1]
```

Og så har vi fundet P og D